MapReduce 大数据实验四—MyJoin_Hive

卢庆宁 MG20330040 邹德润 MG20330094 徐业婷 MF20330097 陈轶洲 MF20330010

December 7, 2020

1 实验任务描述

使用 MapReduce 完成两张表的 join 操作。实验数据在 hdfs://master001:9000/data/hive_myjoin 目录下。单机测试可以使用 FTP"实验要求"目录下的测试数据集。

- 1) 输入数据为 order.txt 和 product.txt;
- 2) 先将这两个文件通过使用 MapReduce 进行 join 操作,将结果输出到 HDFS 的个人目录上;
- 3) 进入 SQL On Hadoop 页面, 使用 Hive 建表管理上一步输出的结果;
- 4) 最后在 Hive 上通过 show tables 能查看到名为 orders 的表,并且通过 select 语句能查出内容。

2 实验设计

2.1 实验环境

Linux 环境	Java 版本	Hadoop 版本	IDE	Maven	集群名称
Ubuntu18.04	jdk1.8	hadoop2.7.1	ItelliJ IDEA(mac os)	maven3.6	2021st20

2.2 实验任务流程

- 1) 小组开会进行任务的分配, 伪代码的设计, 并按照讨论得出的思路进行实现
- 2) 小组成员进行具体代码的编写,利用 maven 管理项目,生成 jar 包,进行本 地测试
- 3) 进行集群的测试,查看结果,撰写实验报告

3 实验具体实现

本次实验的要求是将两张表中的数据进行连接,我们的实现借鉴了课堂 ppt 与书本代码的思路。

3.1 设计思路

Mapper 的输入为待合并的两张表中的每一行数据,输出的 Key 为标记了来源表的 Join 的字段内容, Value 为原表的记录。

Reducer 在接收到同一个 Key 的记录后遍历 Values, 并根据 Key 中不同的来源表标签执行不同操作: "product"——将该条记录加入到一个 List 中; "order"——遍历上一种情况生成的 List,对 List 中的每一条来自产品的数据生成 join 结果并输出。(在区分复合键时进行二次排序,确保分类后 product 记录出现在 order 记录之前。)

3.2 覆写

进行了 Map 类和 Reduce 类的重写,并实现了 Partitioner、WritableComparable 和 WritableComparator 方法。

3.3 TaggedKey 复合键

3.3.1 实现思路

将两张表连接利用的是他们记录中相同的 product_id, 除此以外我们还需要标记这条数据来自哪个文件,故需要设计一个 Tag (IntWritable 类型)。将这二者结合得到 <Text product_id, IntWritable Tag>,就是本实验中需要使用的复合键。

为了定义复合键我们还需要实现 Writable Comparable 接口:利用二次排序,首先比较 product_id,若不同则返回比较结果,若相同则继续比较 Tag,并返回 Tag 的比较结果。

3.3.2 实际代码

```
//WritableComparable
public static class TaggedKey implements
    WritableComparable<TaggedKey>{
    private Text joinKey = new Text();//product_id
    private IntWritable tag = new IntWritable();//Tag
    //implement compareTo()
    public int compareTo(TaggedKey taggedKey){
        //compare product_id
        int compareValue = joinKey.compareTo(taggedKey.getJoinKey());
        //if product_id equals, then compare Tag
        if (compareValue == 0){
            compareValue = tag.compareTo(taggedKey.getTag());
        }
}
```

```
return compareValue;
  }
  public void readFields(DataInput in) throws IOException{
     joinKey.readFields(in);
     tag.readFields(in);
  }
  //implement write() and set()
  public void write(DataOutput out) throws IOException{
     joinKey.write(out);
     tag.write(out);
  }
  public void set(String joinKey, int tag){
     this.joinKey.set(joinKey);
     this.tag.set(tag);
  }
  //implement get() to get product_id or Tag
  public Text getJoinKey(){
     return joinKey;
  }
  public IntWritable getTag(){
     return tag;
  }
}
```

3.4 Map 类

3.4.1 输入输出格式

输入	<longwritable, text=""></longwritable,>
输出	$<\!$

3.4.2 实现思路

首先获取文件名并去除文件名后缀(得到"product"或"order"),然后对内容进行读取,此时读取的是文件的每一行。根据来源文件设置 Tag(IntWritable 类型):来自 product 的数据的 Tag 置为 1,来自 order 的数据的 Tag 置为 2。根据不同 Tag 就能从文本中提取不同来源文件的 product_id。将复合键 <Text product_id, IntWritable Tag> 作为 Key,数据 Text value 作为 value 输出。

3.4.3 实际代码

```
//Mapper
public static class DataMapper extends Mapper<LongWritable, Text,
    TaggedKey, Text>{
```

```
@Override
  protected void map(LongWritable key, Text value, Context context)
  throws IOException, InterruptedException{
     String[] columns = value.toString().split(" ");
     TaggedKey taggedKey = new TaggedKey();
     //setting <key, value> depends on filename
     FileSplit fileSplit = (FileSplit)context.getInputSplit();
     String fileName = fileSplit.getPath().getName();
     if(fileName.startsWith("product")){
        //columns[0] is pid in product.txt, tag is 1
        taggedKey.set(columns[0], 1);
        context.write(taggedKey, value);
     } else if(fileName.startsWith("order")){
        //columns[2] is pid in order.txt, tag is 2
        taggedKey.set(columns[2], 2);
        context.write(taggedKey, value);
     }
  }
}
```

3.5 Partitioner 类

3.5.1 实现思路

默认情况下,Hadoop 会对 Key 进行哈希,以保证相同的 Key 会分配到同一个 Reducer 中。由于我们改变了 Key 的结构,因此需要重新编写分区函数: 只利用 product_id 分区,而忽略 Tag 的不同。这样可以使不同文件中具有相同 product_id 的记录分到一个 Reducer 中。

3.5.2 实际代码

3.6 WritableComparator 类

3.6.1 实现思路

同 Partitioner, 调用 reduce 函数需要传入同一个 Key 的所有记录, 这就需要重新定义分组函数.

3.6.2 实际代码

```
//WritableComparator
public static class TaggedJoinComparator extends WritableComparator{

public TaggedJoinComparator(){
    super(TaggedKey.class, true);
}

@SuppressWarnings("rawtypes")
@Override
public int compare(WritableComparable a, WritableComparable b){
    TaggedKey key1 = (TaggedKey) a;
    TaggedKey key2 = (TaggedKey) b;
    return key1.getJoinKey().compareTo(key2.getJoinKey());
}
```

3.7 Reduce 类

3.7.1 输入输出格式

输入	$<\!$
输出	<nullwritable, iterable="">=<records[]></records[]></nullwritable,>

3.7.2 实现思路

因为 partitioner 仅按照不同的 product_id 划分,所以对于一个 Reducer,包含了 text 和不同的 Tag,因此我们需要区分每条记录来自 product 还是 order。设置全局变量 List<String>products,遍历记录,当这条记录来自 produc 时,我们将该 Text 转换成 String 并存入 products 中;当这条记录来自 order 时,我们遍历 products,将其中每条 product 记录与该 order 记录进行 join 操作并输出。

因为最终只要求输出连接后的记录,所以将输出的 Key 置为 NullWritable。

3.7.3 实际代码

```
//Reducer
public static class JoinReducer extends Reducer<TaggedKey, Text,</pre>
    NullWritable, Text>{
  List<String> products = new ArrayList<String>();//save records
       from product
  @Override
  protected void reduce(TaggedKey key, Iterable<Text> values,
       Context context)
  throws IOException, InterruptedException {
     for (Text value : values) {
        switch (key.getTag().get()) {
          case 1: // product
          products.add(value.toString());//add to products
          break;
          case 2: // order
          String[] order = value.toString().split(" ");
          for (String productString : products) {
             String[] product = productString.split(" ");
             //join data
             if(order[2].equals(product[0])) {
                List<String> output = new ArrayList<String>();
                output.add(order[0]);
                output.add(order[1]);
                output.add(order[2]);
                output.add(product[1]);
                output.add(product[2]);
                output.add(order[3]);
                //output
                context.write(NullWritable.get(), new
                    Text(StringUtils.join(output, " ")));
             }
          }
          break;
          default:
          assert false;
     }
  }
}
```

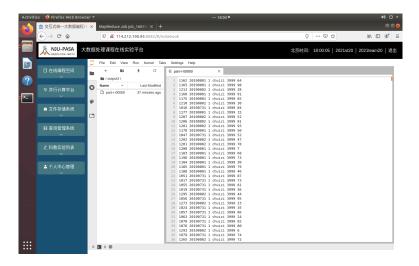
4 实验运行与结果分析

4.1 配置管理

利用 maven 进行包的依赖项的添加和项目的打包管理。生成 jar 包类型。具体见 pom.xml 文件。

4.2 生成 jar 包运行结果

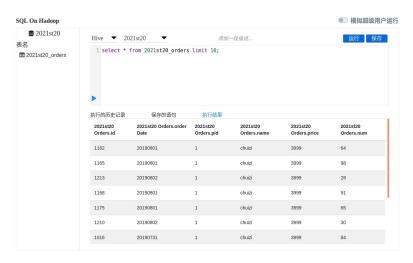
输出结果文件在 HDFS 上的路径: /user/2021st20/output3。 两张表连接生成的结果文件为 part-r-00000,显示如下:



4.3 Hive 输出结果文件

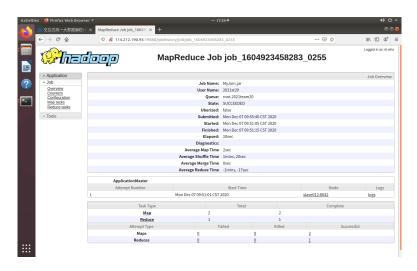
利用上一小节生成的 part-r-00000 文件建表, 在 SQL On Hadoop 中输入如下指令:

create table 2021st20_orders(id int,order_date string,pid string,name string,price int,num int) row format delimited fields terminated by ''location '/user/2021st20/output3/'; 利用 select 语句查看此表:



4.4 Web-ui 结果

 ${\rm Job~ID:~job_1604923458283_0255}$



5 实验总结和参考

5.1 实验总结

- 1) 本次实现通过自己实现 hadoop 的 mapreduce 程序,了解了对于 map-reduce 程序编写,懂得了设计的重要性,并且通过 maven 管理了项目,使得项目的打包运行更方便;
- 2) 同时小组通过开会等,分工明确,互相帮助,共同完成这次实验,体现了团队协作的重要性,在一个项目中团队精神是不可缺少的;
- 3) 在实验中遇到了并行问题,通过询问助教后得到解决。因为 hadoop 不保证 一个 reducer 只执行一次 reduce, 所以设计时需要格外注意保护各个变量的 信息;
- 4) 最后感谢助教和其他同学对本次实验提供的帮助。

5.2 实验参考

- 1) 深入理解 Reduce-side Join
- 2) Hadoop-MapReduce-Reduce 阶段调用 reduce() 方法过程源